

Laboratorio 8

Desafíos enfrentados

En este laboratorio, enfrentamos varios retos desde la elección de modelos hasta el despliegue en una aplicación web. Uno de los principales desafíos fue la preparación de los datos. Durante el preprocesamiento, usamos técnicas como One-Hot Encoding para variables categóricas, lo cual incrementó mucho el número de columnas y generó inconsistencias entre las fases de entrenamiento y predicción. Esta expansión en las características nos obligó a prestar atención extra al control de los datos procesados para que el modelo pudiera manejarlos sin problemas.

Otro reto importante fue dar con la configuración ideal de los hiperparámetros. En la fase de ajuste, utilizamos validación cruzada para probar distintas combinaciones y optimizar el rendimiento. Aunque este proceso mejoró la precisión, fue necesario dedicarle bastante tiempo y análisis para evitar que el modelo se sobreajustara y así mantener su capacidad de generalización.

El despliegue en una aplicación web con Streamlit también trajo sus complicaciones. Encontramos problemas de compatibilidad entre versiones de algunas bibliotecas, así como errores al cargar archivos y rutas. Esto requirió que verificáramos los entornos de ejecución para evitar problemas de importación y asegurar que Streamlit pudiera ejecutar el modelo de forma estable.

Lecciones Aprendidas

Este proyecto nos dejó claro lo fundamental que es tener un preprocesamiento exhaustivo y consistente. Conforme avanzábamos, entendimos mejor cómo la calidad de los datos afecta directamente la precisión del modelo, destacando la importancia de revisar cada transformación aplicada para lograr resultados confiables.

También aprendimos el valor de optimizar los hiperparámetros, una herramienta clave para mejorar la precisión y eficiencia del modelo. La validación cruzada fue útil no solo para encontrar la mejor configuración, sino también para evaluar si el modelo lograba evitar el sobreajuste y si mantenía un desempeño sólido con datos nuevos.

Evaluación de fortalezas y limitaciones

El enfoque que utilizamos mostró ventajas significativas, especialmente con modelos avanzados como Random Forest y Gradient Boosting, que resultaron efectivos al manejar datos complejos y múltiples variables. Estos modelos también ofrecieron la flexibilidad de ajustar sus parámetros para maximizar la precisión sin comprometer la velocidad.

Sin embargo, el proyecto también evidenció algunas limitaciones. La etapa de preprocesamiento fue más compleja de lo esperado, en especial con la transformación de variables categóricas, lo cual llevó a un crecimiento considerable en el número de columnas y generó problemas de compatibilidad en los datos. Además, el ajuste de hiperparámetros demandó bastante tiempo y recursos, lo que complicó el proceso de optimización.

Sugerencias

Para proyectos futuros de mayor escala, sería beneficioso adoptar entornos de desarrollo más robustos, como Docker. Esto facilitaría la replicación de configuraciones y minimizaría los problemas de compatibilidad en producción. Trabajar de forma local y en distintos ambientes generó inconvenientes técnicos en este proyecto, algo que podría mitigarse con una configuración más estructurada y replicable.